

# 循环神经网络与LSTM

---

# 主要内容

---

## ■ 神经网络与循环神经网络

1. 强大的功能
2. 层级结构
3. 多种RNN

## ■ LSTM

1. 长时依赖问题
2. “记忆细胞”与状态

## ■ LSTM变体

1. GRU等
-

# 循环神经网络与应用

## □ 模仿论文(连公式都格式很正确)

For  $\bigoplus_{n=1,\dots,m}$  where  $\mathcal{L}_{m,\bullet} = 0$ , hence we can find a closed subset  $\mathcal{H}$  in  $\mathcal{H}$  and any sets  $\mathcal{F}$  on  $X$ ,  $U$  is a closed immersion of  $S$ , then  $U \rightarrow T$  is a separated algebraic space.

*Proof.* Proof of (1). It also start we get

$$S = \text{Spec}(R) = U \times_X U \times_X U$$

and the comparicoly in the fibre product covering we have to prove the lemma generated by  $\coprod Z \times_U U \rightarrow V$ . Consider the maps  $M$  along the set of points  $\text{Sch}_{fppf}$  and  $U \rightarrow U$  is the fibre category of  $S$  in  $U$  in Section, ?? and the fact that any  $U$  affine, see Morphisms, Lemma ?? . Hence we obtain a scheme  $S$  and any open subset  $W \subset U$  in  $\text{Sh}(G)$  such that  $\text{Spec}(R') \rightarrow S$  is smooth or an

$$S = \bigcup U_i \times_{S_i} U_i$$

which has a nonzero morphism we may assume that  $f_i$  is of finite presentation over  $S$ . We claim that  $\mathcal{O}_{X,x}$  is a scheme where  $x, x', s'' \in S'$  such that  $\mathcal{O}_{X,x'} \rightarrow \mathcal{O}'_{X',x'}$  is separated. By Algebra, Lemma ?? we can define a map of complexes  $\text{GL}_{S'}(x'/S'')$  and we win. □

To prove study we see that  $\mathcal{F}|_U$  is a covering of  $\mathcal{X}'$ , and  $\mathcal{T}_i$  is an object of  $\mathcal{F}_{X/S}$  for  $i > 0$  and  $\mathcal{F}_p$  exists and let  $\mathcal{F}_i$  be a presheaf of  $\mathcal{O}_X$ -modules on  $\mathcal{C}$  as a  $\mathcal{F}$ -module. In particular  $\mathcal{F} = U/\mathcal{F}$  we have to show that

$$\tilde{M}^\bullet = \mathcal{I}^\bullet \otimes_{\text{Spec}(k)} \mathcal{O}_{S,s} - i_X^{-1} \mathcal{F}$$

is a unique morphism of algebraic stacks. Note that

$$\text{Arrows} = (\text{Sch}/S)_{fppf}^{opp}, (\text{Sch}/S)_{fppf}$$

and

$$V = \Gamma(S, \mathcal{O}) \mapsto (U, \text{Spec}(A))$$

is an open subset of  $X$ . Thus  $U$  is affine. This is a continuous map of  $X$  is the inverse, the groupoid scheme  $S$ .

*Proof.* See discussion of sheaves of sets. □

The result for prove any open covering follows from the less of Example ?? . It may replace  $S$  by  $X_{spaces, \acute{e}tale}$  which gives an open subspace of  $X$  and  $T$  equal to  $S_{Zar}$ , see Descent, Lemma ?? . Namely, by Lemma ?? we see that  $R$  is geometrically regular over  $S$ .

**Lemma 0.1.** Assume (3) and (3) by the construction in the description.

Suppose  $X = \lim |X|$  (by the formal open covering  $X$  and a single map  $\text{Proj}_X(\mathcal{A}) = \text{Spec}(B)$  over  $U$  compatible with the complex

$$\text{Set}(\mathcal{A}) = \Gamma(X, \mathcal{O}_{X, \mathcal{O}_X}).$$

When in this case of to show that  $\mathcal{Q} \rightarrow \mathcal{C}_{Z/X}$  is stable under the following result in the second conditions of (1), and (3). This finishes the proof. By Definition ?? (without element is when the closed subschemes are catenary. If  $T$  is surjective we may assume that  $T$  is connected with residue fields of  $S$ . Moreover there exists a closed subspace  $Z \subset X$  of  $X$  where  $U$  in  $X'$  is proper (some defining as a closed subset of the uniqueness it suffices to check the fact that the following theorem

(1)  $f$  is locally of finite type. Since  $S = \text{Spec}(R)$  and  $Y = \text{Spec}(R)$ .

*Proof.* This is form all sheaves of sheaves on  $X$ . But given a scheme  $U$  and a surjective étale morphism  $U \rightarrow X$ . Let  $U \cap U = \coprod_{i=1,\dots,n} U_i$  be the scheme  $X$  over  $S$  at the schemes  $X_i \rightarrow X$  and  $U = \lim_i X_i$ . □

The following lemma surjective restrocomposes of this implies that  $\mathcal{F}_{x_0} = \mathcal{F}_{x_0} = \mathcal{F}_{x_0, \dots, 0}$ .

**Lemma 0.2.** Let  $X$  be a locally Noetherian scheme over  $S$ ,  $E = \mathcal{F}_{X/S}$ . Set  $\mathcal{I} = \mathcal{I}_1 \subset \mathcal{I}'_n$ . Since  $\mathcal{I}^n \subset \mathcal{I}^n$  are nonzero over  $i_0 \leq \mathfrak{p}$  is a subset of  $\mathcal{J}_{n,0} \circ A_2$  works.

**Lemma 0.3.** In Situation ?? . Hence we may assume  $\mathfrak{q}' = 0$ .

*Proof.* We will use the property we see that  $\mathfrak{p}$  is the mex functor (??). On the other hand, by Lemma ?? we see that

$$D(\mathcal{O}_{X'}) = \mathcal{O}_X(D)$$

where  $K$  is an  $F$ -algebra where  $\delta_{n+1}$  is a scheme over  $S$ . □

# 循环神经网络与应用

---

## □ 模仿莎士比亚的作品

PANDARUS:

Alas, I think he shall be come approached and the day  
When little strain would be attain'd into being never fed,  
And who is but a chain and subjects of his death,  
I should not sleep.

Second Senator:

They are away this miseries, produced upon my soul,  
Breaking and strongly should be buried, when I perish  
The earth and thoughts of many states.

DUKE VINCENTIO:

Well, your wit is in the care of side and that.

Second Lord:

They would be ruled after this chamber, and  
my fair nudes begun out of the fact, to be conveyed,  
Whose noble souls I'll have the heart of the wars.

Clown:

Come, sir, I will make did behold your worship.

VIOLA:

I'll drink it.

# 循环神经网络与应用

---

## □ 模仿小四的作品

每个人，闭上眼睛的时候，才能真正面对光明

他们在吱呀作响的船舷上，静静看着世界，没有痛苦的声音，碎裂的海洋里摇晃出阵阵沉默，吞噬过来。他们的躯体，一点，一点，逐渐暗淡在

你们虔诚的看着远方，我抬起头，不经意间，目光划过你们的面庞，上面淡淡的倔强印，那么坚强

尘世凡间  
沉睡亿万光年的年轻战士  
萦绕不散的寂寞烟云中  
静候在末世岛屿之上  
守候，女王何时归来  
你的目光延向她迟归的方向  
缓缓推进的海浪  
这最后一夜  
荡漾

---

# 循环神经网络与应用

---

## □ 看图说话

### 看图说话和问答



一辆火车沿着森林边的铁轨驶过。



问：冲浪板是什么颜色的？

答：黄色。




一只狗在盆里玩。



# 神经网络到循环神经网络

---

□ 我们知道神经网络结构如下



□ 那循环神经网络和它是什么关系呢？

---

# 循环神经网络

---

## □ 为什么有BP神经网络，CNN，还要RNN？

- 传统神经网络(包括CNN)，输入和输出都是互相独立的。

- 图像上的猫和狗是分隔开的，但有些任务，后续的输出和之前的内容是相关的。

- “我是中国人，我的母语是\_\_\_\_”

- RNN引入“记忆”的概念

- 循环2字来源于其每个元素都执行相同的任务。


- 但是输出依赖于 输入 和 “记忆”

---




# 循环神经网络之 结构

□ 简单来看，把序列按时间展开



# 循环神经网络之 结构



- $x_t$  是时间  $t$  处的输入
- $s_t$  是时间  $t$  处的“记忆”， $s_t = f(Ux_t + Ws_{t-1})$ ， $f$  可以是  $\tanh$  等
- $o_t$  是时间  $t$  出的输出，比如是预测下个词的话，可能是  $\text{softmax}$  输出的属于每个候选词的概率

# 循环神经网络之 结构细节

---


- 可以把隐状态 $S_t$ 视作“记忆体”，捕捉了之前时间点上的信息。
  - 输出 $O_t$ 由当前时间及之前所有的“记忆”共同计算得到。
  - 很可惜，实际应用中， $S_t$ 并不能捕捉和保留之前所有信息（记忆有限？）
  - 不同于CNN，这里的RNN其实整个神经网络都共享一组参数（ $U, V, W$ ），极大减小了需要训练和预估的参数量
  - 图中的 $O_t$ 在有些任务下是不存在的，比如文本情感分析，其实只需要最后的output结果就行
-

# 不同类型的RNN

---

## □ 双向RNN


- 有些情况下，当前的输出不只依赖于之前的序列元素，还可能依赖之后的序列元素
- 比如从一段话踢掉部分词，让你补全
- 直观理解：2个RNN叠加



# 不同类型的RNN

## □ 深层双向RNN

□ 和双向RNN的区别是每一步/每个时间点我们设定多层结构



# 循环神经网络之 LSTM

---

- 前面提到的RNN解决了，对之前的信息保存的问题
  - 但是！从在长期依赖的问题。
    - 看电影的时候，某些情节的推断需要依赖很久以前的一些细节。
    - 很多其他的任务也一样。
    - 很可惜随着时间间隔不断增大时，RNN 会丧失学习到连接如此远的信息的能力。
    - 也就是说，记忆容量有限，一本书从头到尾一字不漏的去记，肯定离得越远的东西忘得越多。
    - 怎么办：LSTM
-

# 循环神经网络之 LSTM


---

- LSTM是RNN一种，大体结构几乎一样。区别是？
    - 它的“记忆细胞”改造过。
    - 该记的信息会一直传递，不该记的会被“门”截断。
-




# 循环神经网络之 LSTM

□ 之前提到的RNN结构如下



# 循环神经网络之 LSTM


□ 咱们把“记忆细胞”表示得炫酷一点



# 循环神经网络之 LSTM

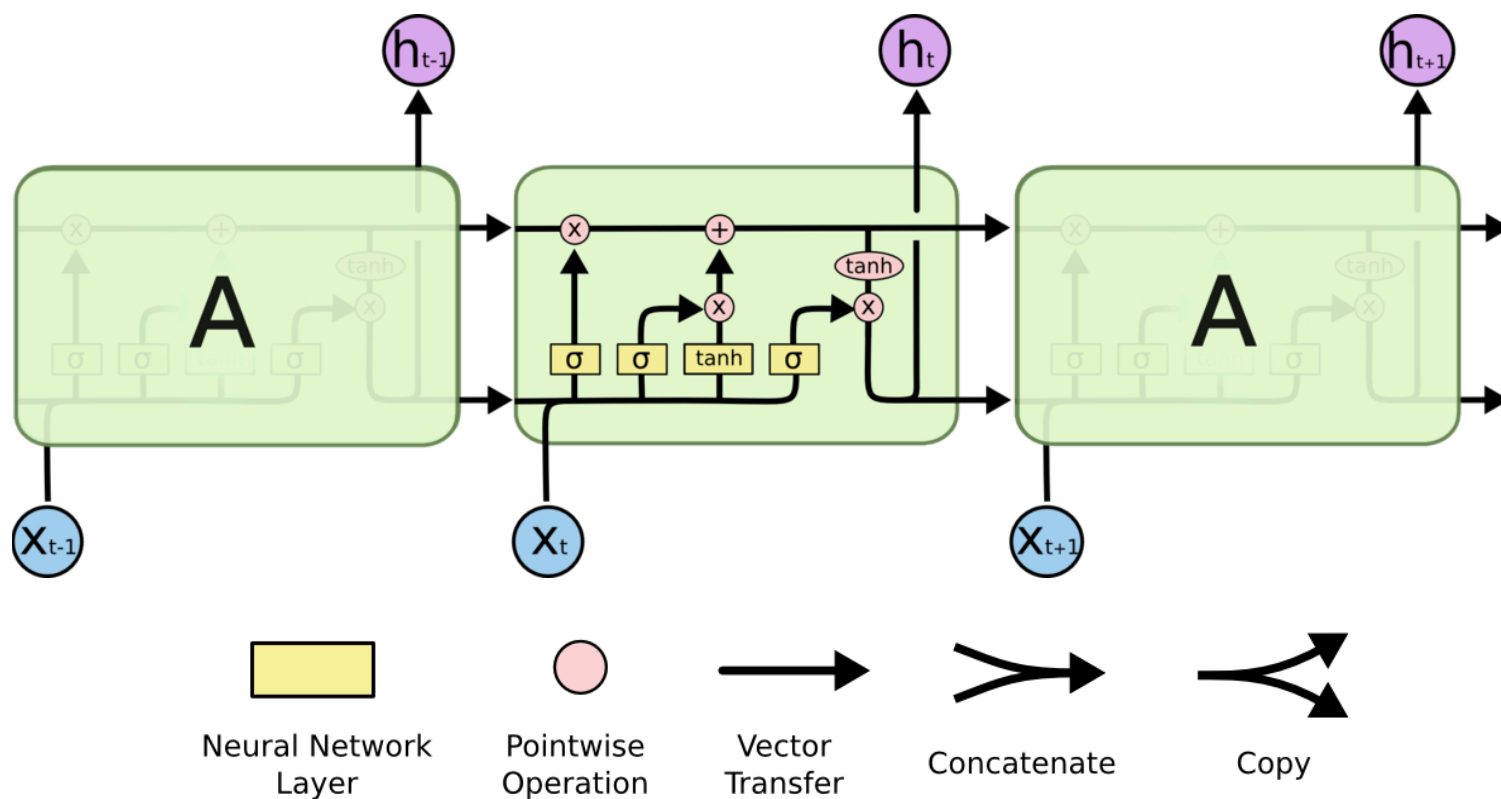
□ LSTM呢？

□ “记忆细胞” 变得稍微复杂了一点点



# 循环神经网络之 LSTM


□ 图太复杂，细节看不懂？别着急，我们解释解释。



# 循环神经网络之 LSTM

□ LSTM关键：“细胞状态”


□ 细胞状态类似于传送带。直接在整个链上运行，只有一些少量的线性交互。信息在上面流传保持不变会很容易。



# 循环神经网络之 LSTM


---

- LSTM怎么控制“细胞状态”？
  - 通过“门”让信息选择性通过，来去除或者增加信息到细胞状态
  - 包含一个sigmoid神经网络层 和 一个pointwise乘法操作
  - Sigmoid 层输出0到1之间的概率值，描述每个部分有多少量可以通过。  
0代表“不许任何量通过”，1就指“允许任意量通过”



# LSTM的几个关键“门”与操作

- 第1步：决定从“细胞状态”中丢弃什么信息 => “忘记门”
- 比如完形填空中填“他”或者“她”的问题，细胞状态可能包含当前主语的类别，当我们看到新的代词，我们希望忘记旧的代词。




$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f)$$



# LSTM的几个关键“门”与操作

□ 第2步：决定放什么新信息到“细胞状态”中

- ① Sigmoid层决定什么值需要更新
- ② Tanh层创建一个新的候选值向量  $\tilde{C}_t$
- ③ 上述2步是为状态更新做准备




$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$
$$\tilde{C}_t = \tanh(W_C \cdot [h_{t-1}, x_t] + b_C)$$

# LSTM的几个关键“门”与操作

## □ 第3步：更新“细胞状态”

- ① 更新 $C_{t-1}$ 为 $C_t$
- ② 把旧状态与 $f_t$ 相乘，丢弃掉我们确定需要丢弃的信息
- ③ 加上 $i_t * \tilde{C}_t$ 。这就是新的候选值，根据我们决定更新每个状态的程度进行变化。




$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t$$

# LSTM的几个关键“门”与操作

□ 第4步：基于“细胞状态”得到输出

- ① 首先运行一个sigmoid 层来确定细胞状态的哪个部分将输出
- ② 接着用tanh处理细胞状态(得到一个在-1到1之间的值)，再将它和sigmoid门的输出相乘，输出我们确定输出的那部分。
- ③ 比如我们可能需要单复数信息来确定输出“他”还是“他们”




$$o_t = \sigma(W_o [h_{t-1}, x_t] + b_o)$$

$$h_t = o_t * \tanh(C_t)$$

# LSTM的变体

## □ 变种1

- 增加“peephole connection”
- 让 门层 也会接受细胞状态的输入。



$$f_t = \sigma(W_f \cdot [C_{t-1}, h_{t-1}, x_t] + b_f)$$


$$i_t = \sigma(W_i \cdot [C_{t-1}, h_{t-1}, x_t] + b_i)$$

$$o_t = \sigma(W_o \cdot [C_t, h_{t-1}, x_t] + b_o)$$

# LSTM的变体

## □ 变种2


- 通过使用 coupled 忘记和输入门
- 之前是分开确定需要忘记和添加的信息，这里是一同做出决定。



$$C_t = f_t * C_{t-1} + (1 - f_t) * \tilde{C}_t$$

# LSTM的变体

- 变种3: Gated Recurrent Unit (GRU), 2014年提出
  - 将忘记门和输入门合成了一个单一的 更新门
  - 同样还混合了细胞状态和隐藏状态, 和其他一些改动。
  - 比标准LSTM简单。



$$z_t = \sigma(W_z \cdot [h_{t-1}, x_t])$$

$$r_t = \sigma(W_r \cdot [h_{t-1}, x_t])$$

$$\tilde{h}_t = \tanh(W \cdot [r_t * h_{t-1}, x_t])$$

$$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$$

# LSTM比较?

---

- 2015的paper 《LSTM: A Search Space Odyssey》中，对各种变体做了对比，发现其实本质上它们大同小异。
  - 2015的论文 《An Empirical Exploration of Recurrent Network Architectures》中，google和facebook的大神尝试了1w+种RNN架构，发现并非所有任务上LSTM都表现最好。
  - 现在有更多的RNN研究方向，比如attention model和Grid LSTM等等
-